Informe Final

Proyecto Módulo 8

Clasificador Inteligente de Imágenes de Ropa

Tomás Saldaña

Índice

1. Introducción **3**

2. Objetivos **3**

2.1. Objetivo general 3

2.2. Objetivos específicos 3

3. Dataset utilizado **3**

3.1. Ejemplos de imágenes 4

4. Preprocesamiento de los datos **4**

5. Modelo 1: Red neuronal densa **4**

5.1. Arquitectura del modelo 5

5.2. Resultados del modelo denso 5

6. Modelo 2: Red neuronal convolutiva **6**

6.1. Arquitectura del modelo 7

6.2. Resultados del modelo CNN 7

7. Comparación de modelos **8**

8. Predicciones del modelo **9**

9. Conclusiones **9**

10. Trabajo futuro **9**

1. Introducción

En el contexto del comercio electrónico, la correcta clasificación de productos es un proceso clave para garantizar una adecuada organización del catálogo y mejorar la experiencia de usuario. Sin embargo, cuando este proceso se realiza de forma manual, puede generar errores, inconsistencias y retrasos operativos.

El presente proyecto aborda este problema mediante el uso de técnicas de *Deep Learning*, específicamente redes neuronales artificiales, con el objetivo de desarrollar un sistema capaz de clasificar automáticamente imágenes de prendas de vestir en distintas categorías.

Para ello, se utilizó el dataset *Fashion-MNIST*, implementando y comparando dos arquitecturas de redes neuronales: una red densa y una red convolutiva.

2. Objetivos

2.1. Objetivo general

Desarrollar un modelo de clasificación automática de imágenes de ropa utilizando técnicas de Deep Learning.

2.2. Objetivos específicos

- Explorar y comprender el dataset Fashion-MNIST.
- Preprocesar los datos para su uso en redes neuronales.
- Implementar una red neuronal densa.
- Implementar una red neuronal convolutiva.
- Evaluar el desempeño de ambos modelos.
- Comparar los resultados obtenidos.

3. Dataset utilizado

El dataset utilizado corresponde a *Fashion-MNIST*, el cual contiene imágenes en escala de grises de 28x28 píxeles pertenecientes a 10 categorías de prendas de vestir.

3.1. Ejemplos de imágenes

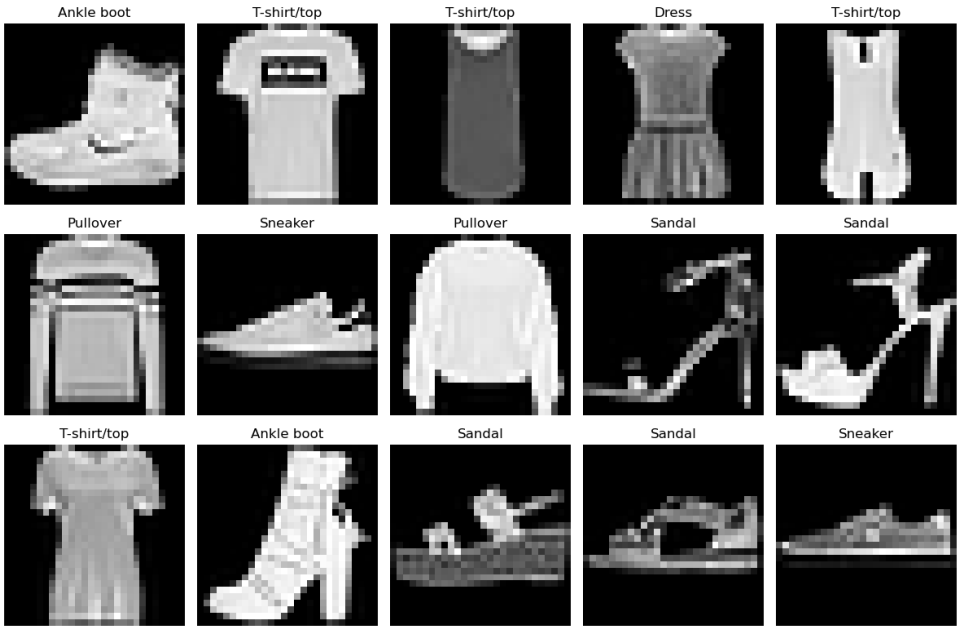

Figura 1: Ejemplos de imágenes del dataset Fashion-MNIST

4. Preprocesamiento de los datos

Se realizó un proceso de normalización de los datos, transformando los valores de los píxeles desde un rango de 0-255 a un rango de 0-1, con el fin de mejorar la estabilidad del entrenamiento.

Además, se aplicaron transformaciones específicas dependiendo del tipo de modelo:

- Red densa: las imágenes fueron aplanadas a vectores de 784 elementos.
- Red convolutiva: las imágenes conservaron su estructura 2D agregando un canal.

5. Modelo 1: Red neuronal densa

Se implementó una red neuronal densa como modelo base, compuesta por capas totalmente conectadas y técnicas de regularización mediante Dropout.

El modelo fue diseñado como una arquitectura base de clasificación multiclase, utilizando capas densas completamente conectadas. Se incorporaron funciones de activación ReLU para introducir no linealidad y una capa de salida Softmax para estimar la probabilidad de pertenencia a cada una de las 10 clases del dataset.

Además, se utilizó Dropout como técnica de regularización para reducir el riesgo de sobreajuste durante el entrenamiento.

5.1. Arquitectura del modelo

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 128)	100,480
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 64)	8,256
dropout_1 (Dropout)	(None, 64)	0
dense_2 (Dense)	(None, 10)	650

Total params: 109,386 (427.29 KB)

Trainable params: 109,386 (427.29 KB)

Non-trainable params: 0 (0.00 B)

Figura 2: Arquitectura del modelo denso

5.2. Resultados del modelo denso

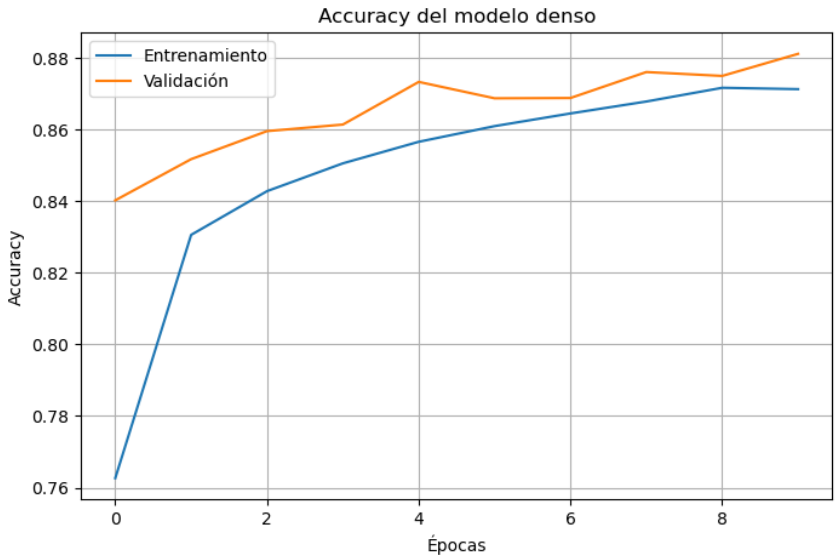

Figura 3: Accuracy del modelo denso

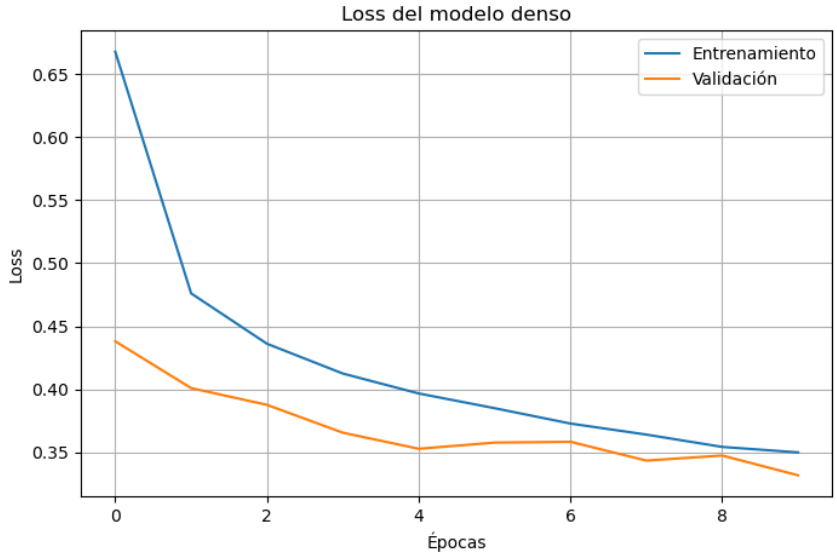

Figura 4: Loss del modelo denso

El modelo alcanzó una exactitud aproximada de 87 % sobre el conjunto de prueba.

Los resultados muestran una evolución estable tanto en entrenamiento como en validación, observándose una mejora progresiva de la exactitud y una disminución de la pérdida a lo largo de las épocas.

Esto indica que el modelo logró aprender patrones útiles del dataset, alcanzando un desempeño satisfactorio como línea base para la tarea de clasificación.

6. Modelo 2: Red neuronal convolutiva

Se implementó una red neuronal convolutiva para mejorar la capacidad de aprendizaje del modelo aprovechando la estructura espacial de las imágenes.

La arquitectura convolutiva fue diseñada para aprovechar la estructura espacial de las imágenes. A diferencia del modelo denso, este enfoque permite extraer características visuales relevantes mediante capas convolutivas y de agrupamiento, mejorando la representación interna de los datos.

Posteriormente, las características extraídas son procesadas por capas densas para realizar la clasificación final.

6.1. Arquitectura del modelo

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 128)	100,480
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 64)	8,256
dropout_1 (Dropout)	(None, 64)	0
dense_2 (Dense)	(None, 10)	650

Total params: 109,386 (427.29 KB)

Trainable params: 109,386 (427.29 KB)

Non-trainable params: 0 (0.00 B)

Figura 5: Arquitectura del modelo CNN

6.2. Resultados del modelo CNN

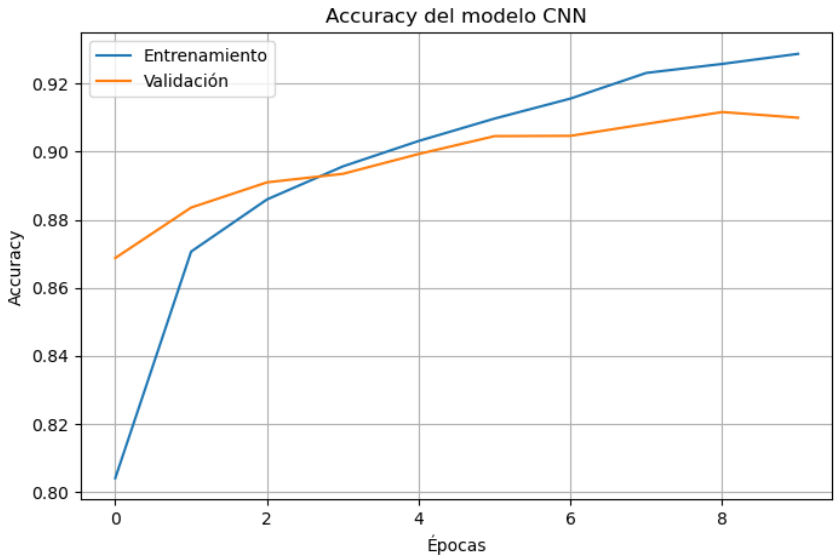

Figura 6: Accuracy del modelo CNN

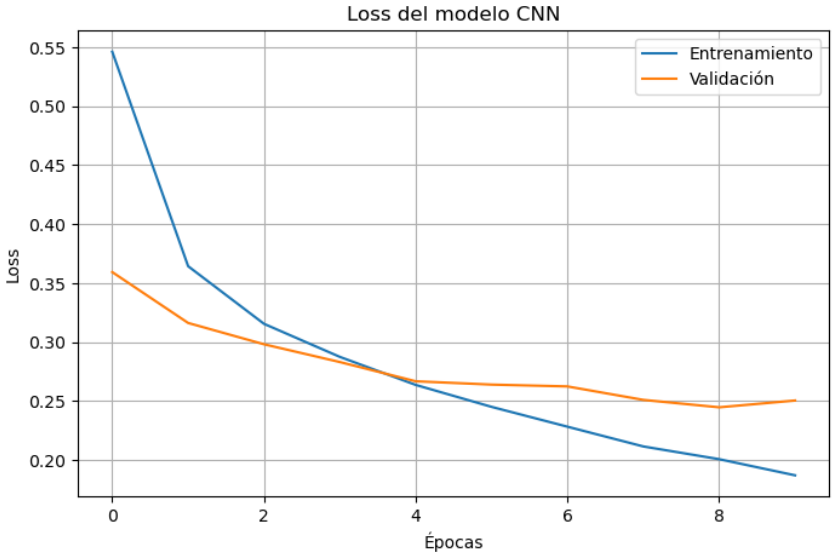

Figura 7: Loss del modelo CNN

El modelo CNN alcanzó una exactitud aproximada de 91 %, superando el desempeño del modelo denso.

7. Comparación de modelos

Modelo	Accuracy	Loss
Red densa	0.87	0.35
CNN	0.91	0.25

Cuadro 1: Comparación de modelos

Los resultados evidencian que la red convolutiva presenta un mejor desempeño debido a su capacidad para capturar patrones espaciales en las imágenes.

8. Predicciones del modelo

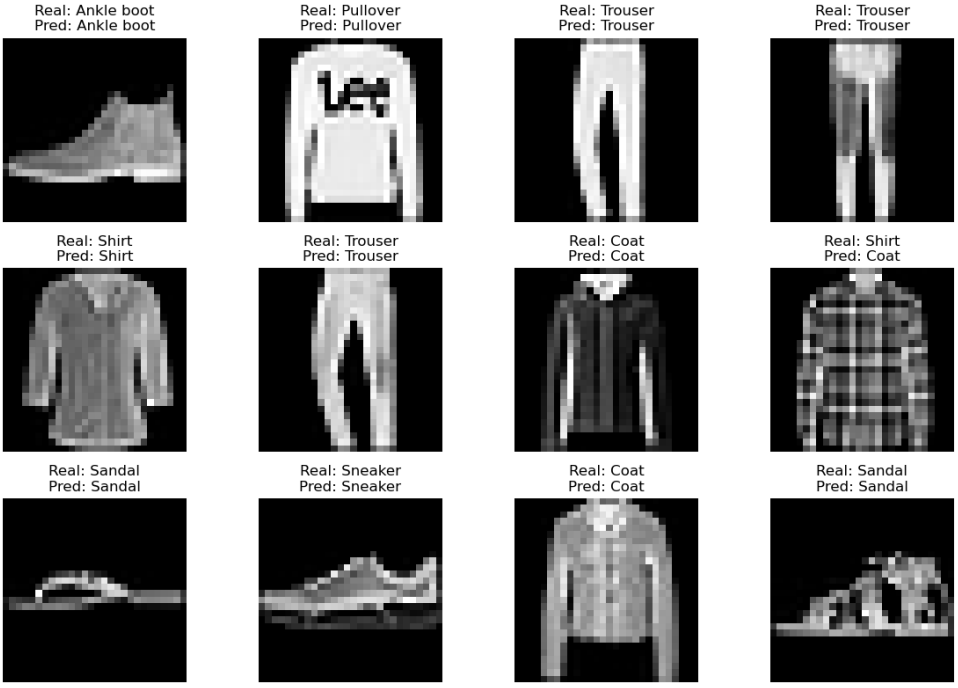

Figura 8: Comparación entre clases reales y predichas

Se observa que el modelo logra clasificar correctamente la mayoría de las imágenes, aunque presenta algunas confusiones en categorías visualmente similares.

9. Conclusiones

El desarrollo del proyecto permitió implementar y comparar dos enfoques de Deep Learning para clasificación de imágenes. Los resultados obtenidos demuestran que las redes convolutivas son más adecuadas para este tipo de problemas.

Se logró construir un modelo funcional capaz de clasificar imágenes de ropa con un nivel de exactitud adecuado, cumpliendo con los objetivos propuestos.

10. Trabajo futuro

Como mejoras futuras, se propone:

- Aplicar técnicas de aumento de datos
- Ajustar hiperparámetros

- Evaluar el modelo con imágenes externas
- Desplegar el modelo en una aplicación real