# Informe Final

Proyecto Módulo 8

Clasificador Inteligente de Imágenes de Ropa

Tomás Saldaña

# Índice

**1. Introducción** **3**

**2. Objetivos** **3**

2.1. Objetivo general . . . . . 3

2.2. Objetivos específicos . . . . . 3

**3. Dataset utilizado** **3**

3.1. Ejemplos de imágenes . . . . . 4

**4. Preprocesamiento de los datos** **4**

**5. Modelo 1: Red neuronal densa** **4**

5.1. Arquitectura del modelo . . . . . 5

5.2. Resultados del modelo denso . . . . . 5

**6. Modelo 2: Red neuronal convolutiva** **6**

6.1. Arquitectura del modelo . . . . . 6

6.2. Resultados del modelo CNN . . . . . 7

**7. Comparación de modelos** **8**

**8. Predicciones del modelo** **8**

**9. Conclusiones** **8**

**10. Trabajo futuro** **9**

# 1. Introducción

En el contexto del comercio electrónico, la correcta clasificación de productos es un proceso clave para garantizar una adecuada organización del catálogo y mejorar la experiencia de usuario. Sin embargo, cuando este proceso se realiza de forma manual, puede generar errores, inconsistencias y retrasos operativos.

El presente proyecto aborda este problema mediante el uso de técnicas de *Deep Learning*, específicamente redes neuronales artificiales, con el objetivo de desarrollar un sistema capaz de clasificar automáticamente imágenes de prendas de vestir en distintas categorías.

Para ello, se utilizó el dataset *Fashion-MNIST*, implementando y comparando dos arquitecturas de redes neuronales: una red densa y una red convolutiva.

# 2. Objetivos

## 2.1. Objetivo general

Desarrollar un modelo de clasificación automática de imágenes de ropa utilizando técnicas de Deep Learning.

## 2.2. Objetivos específicos

- Explorar y comprender el dataset Fashion-MNIST.
- Preprocesar los datos para su uso en redes neuronales.
- Implementar una red neuronal densa.
- Implementar una red neuronal convolutiva.
- Evaluar el desempeño de ambos modelos.
- Comparar los resultados obtenidos.

# 3. Dataset utilizado

El dataset utilizado corresponde a *Fashion-MNIST*, el cual contiene imágenes en escala de grises de 28x28 píxeles pertenecientes a 10 categorías de prendas de vestir.

## 3.1. Ejemplos de imágenes

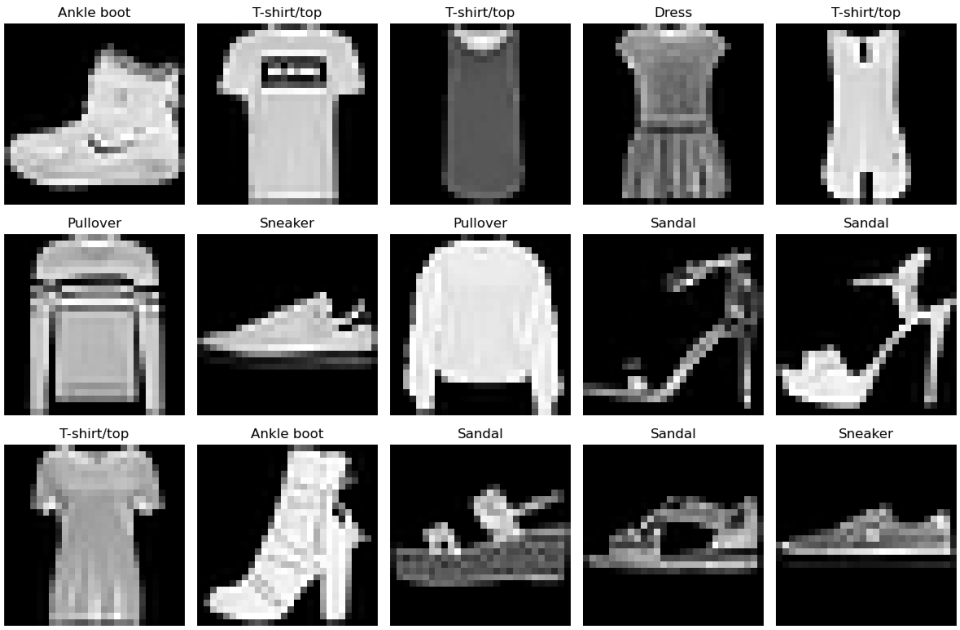


Figura 1: Ejemplos de imágenes del dataset Fashion-MNIST

# 4. Preprocesamiento de los datos

Se realizó un proceso de normalización de los datos, transformando los valores de los píxeles desde un rango de 0-255 a un rango de 0-1, con el fin de mejorar la estabilidad del entrenamiento.

Además, se aplicaron transformaciones específicas dependiendo del tipo de modelo:

- Red densa: las imágenes fueron aplanadas a vectores de 784 elementos.
- Red convolutiva: las imágenes conservaron su estructura 2D agregando un canal.

# 5. Modelo 1: Red neuronal densa

Se implementó una red neuronal densa como modelo base, compuesta por capas totalmente conectadas y técnicas de regularización mediante Dropout.

## 5.1. Arquitectura del modelo

Model: "sequential"

| Layer (type) | Output Shape | Param # |
|---|---|---|
| dense (Dense) | (None, 128) | 100,480 |
| dropout (Dropout) | (None, 128) | 0 |
| dense_1 (Dense) | (None, 64) | 8,256 |
| dropout_1 (Dropout) | (None, 64) | 0 |
| dense_2 (Dense) | (None, 10) | 650 |

Total params: 109,386 (427.29 KB)

Trainable params: 109,386 (427.29 KB)

Non-trainable params: 0 (0.00 B)

Figura 2: Arquitectura del modelo denso

## 5.2. Resultados del modelo denso

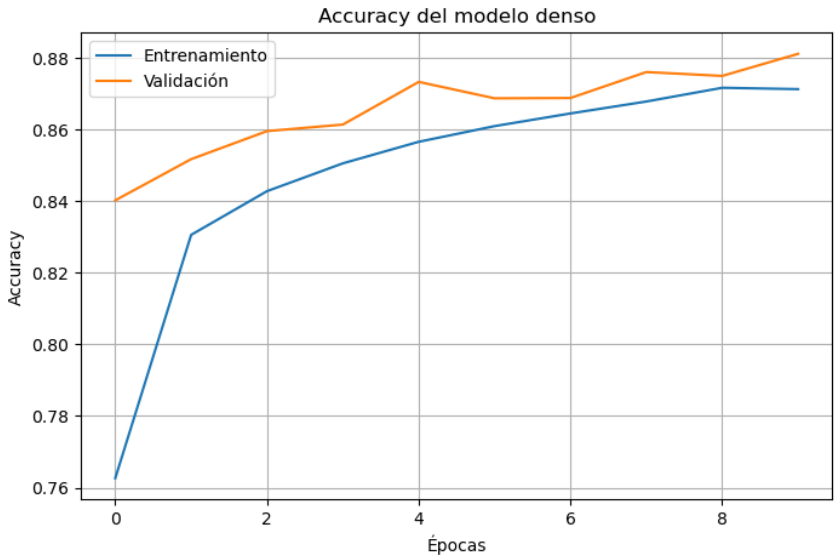


Figura 3: Accuracy del modelo denso

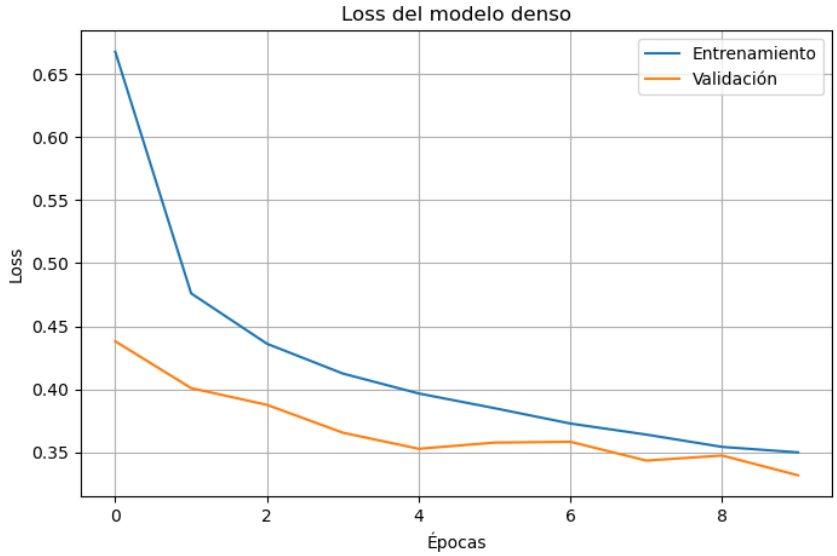


Figura 4: Loss del modelo denso

El modelo alcanzó una exactitud aproximada de 87 % sobre el conjunto de prueba.

# 6. Modelo 2: Red neuronal convolutiva

Se implementó una red neuronal convolutiva para mejorar la capacidad de aprendizaje del modelo aprovechando la estructura espacial de las imágenes.

## 6.1. Arquitectura del modelo

Model: "sequential"

| Layer (type) | Output Shape | Param # |
|---|---|---|
| dense (Dense) | (None, 128) | 100,480 |
| dropout (Dropout) | (None, 128) | 0 |
| dense_1 (Dense) | (None, 64) | 8,256 |
| dropout_1 (Dropout) | (None, 64) | 0 |
| dense_2 (Dense) | (None, 10) | 650 |

Total params: 109,386 (427.29 KB)

Trainable params: 109,386 (427.29 KB)

Non-trainable params: 0 (0.00 B)

Figura 5: Arquitectura del modelo CNN

## 6.2. Resultados del modelo CNN

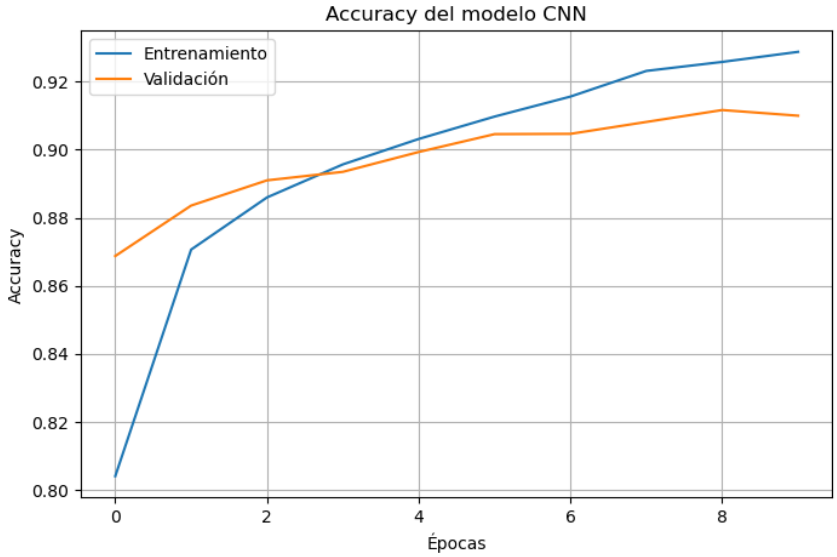


Figura 6: Accuracy del modelo CNN

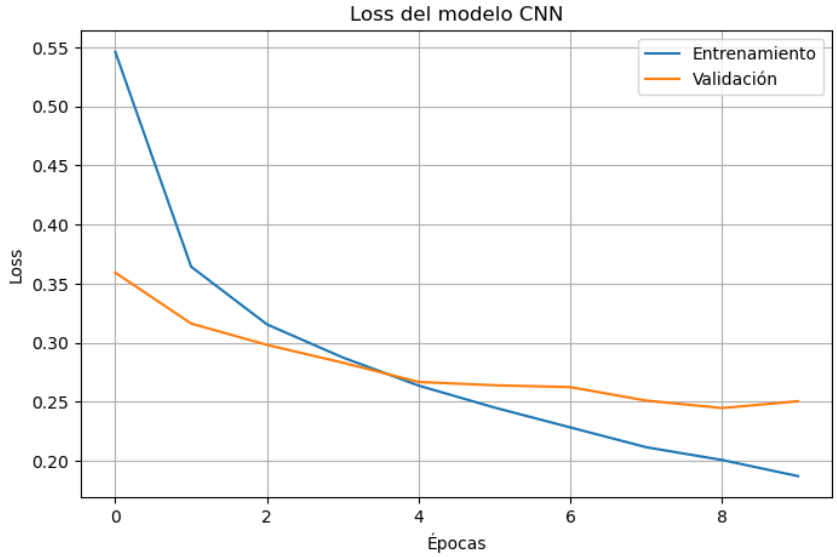


Figura 7: Loss del modelo CNN

El modelo CNN alcanzó una exactitud aproximada de 91 %, superando el desempeño del modelo denso.

# 7. Comparación de modelos

| Modelo | Accuracy | Loss |
|---|---|---|
| Red densa | 0.87 | 0.35 |
| CNN | 0.91 | 0.25 |

Cuadro 1: Comparación de modelos

Los resultados evidencian que la red convolutiva presenta un mejor desempeño debido a su capacidad para capturar patrones espaciales en las imágenes.

# 8. Predicciones del modelo

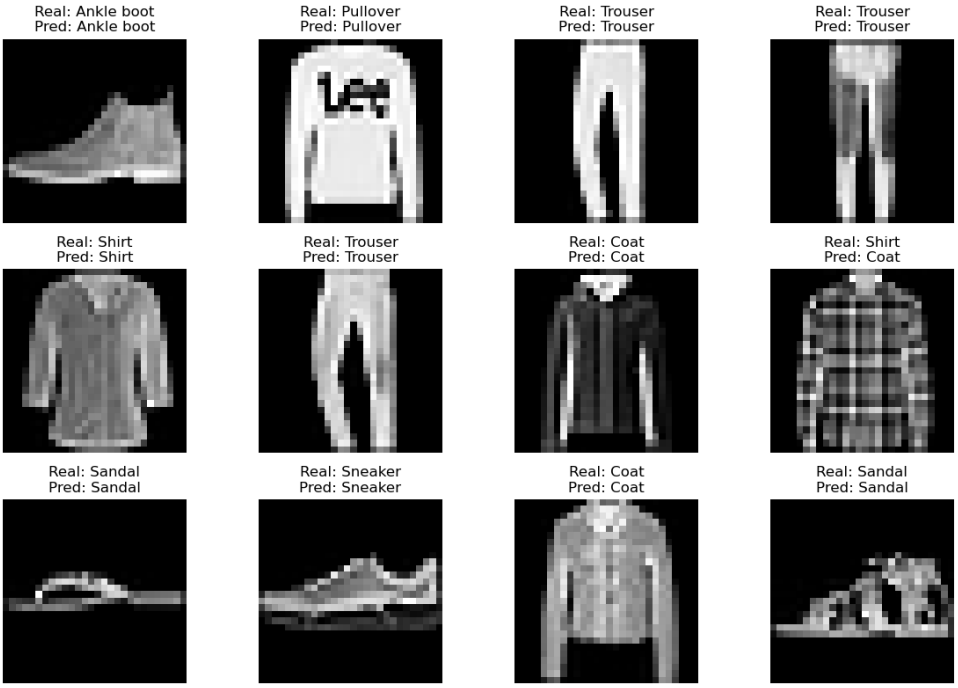


Figura 8: Comparación entre clases reales y predichas

Se observa que el modelo logra clasificar correctamente la mayoría de las imágenes, aunque presenta algunas confusiones en categorías visualmente similares.

# 9. Conclusiones

El desarrollo del proyecto permitió implementar y comparar dos enfoques de Deep Learning para clasificación de imágenes. Los resultados obtenidos demuestran que las

redes convolutivas son más adecuadas para este tipo de problemas.

Se logró construir un modelo funcional capaz de clasificar imágenes de ropa con un nivel de exactitud adecuado, cumpliendo con los objetivos propuestos.

# 10. Trabajo futuro

Como mejoras futuras, se propone:

- Aplicar técnicas de aumento de datos
- Ajustar hiperparámetros
- Evaluar el modelo con imágenes externas
- Desplegar el modelo en una aplicación real